

Zadanie č.3
Strojové učenie a neurónové siete
Predikcia slnečného žiarenia z obrazov oblohy

Peter Muzslay

Akademický rok 2024/2025

Obsah

1	Úvod	4
1.1	Použité technológie	4
1.2	Dataset	4
2	Časť 1: Exploračná dátová analýza	5
2.1	Načítanie a analýza dát	5
2.1.1	Štatistiky cieľovej premennej Irradiance	5
2.1.2	Vizualizácia distribúcie Irradiance	5
2.2	Distribúcia žiarenia podľa mesiacov	6
2.3	Ukážky obrázkov	7
2.3.1	Náhodné vzorky obrázkov	7
2.3.2	Obrázky s nízkym a vysokým žiarením	8
2.4	Korelačná analýza	9
2.4.1	Top 10 korelácií s Irradiance	10
2.5	Detailná analýza top features	10
2.6	Rozdelenie dát	11
3	Časť 2: Konvolučné neurónové siete (CNN)	12
3.1	Architektúra CNN	12
3.2	Konfigurácie hyperparametrov	12
3.3	Výsledky trénovania CNN	13
3.3.1	Najlepšia konfigurácia	13
3.3.2	Analýza overfittingu	13
3.4	História trénovania najlepšieho modelu	14
3.5	Analýza reziduálov	15
3.6	Porovnanie predikcií	16
3.7	Vizualizácia konvolučných filtrov	17
3.8	Bonus: Testovanie na vlastných obrázkoch	19
3.9	Bonus: Predikcia žiarenia o 15 minút	20
4	Časť 3: Transfer Learning a zhlukovanie	21
4.1	Extrakcia príznakov pomocou MobileNetV2	21
4.1.1	Redukcia dimenzie pomocou PCA	21
4.2	Zhlukovanie pomocou K-Means	21
4.2.1	Výber optimálneho počtu zhlukov	21
4.2.2	Vizualizácia zhlukov (t-SNE)	22
4.2.3	Priemerné obrázky pre každý zhluk	22
4.2.4	Distribúcia Irradiance podľa zhlukov	23
4.3	Transfer Learning - Stacking Ensemble	24
4.3.1	Vstupy modelu	24
4.3.2	Výsledky Transfer Learning	24
4.4	Porovnanie CNN vs. Transfer Learning	25
4.5	Vizualizácia výsledkov Transfer Learning	25
4.6	Analýza najhorších predikcií	26
4.7	Bonus: Fúzia modelov	27

5	Záver	29
5.1	Zhrnutie výsledkov	29
5.2	Finálne porovnanie modelov	29

1 Úvod

Projekt sa zaoberá predikciou intenzity slnečného žiarenia (Irradiance) z RGB obrázkov oblohy. Využívame dáta zo švajčiarskej meteorologickej stanice Alpnach, ktorá obsahuje snímky oblohy spolu s meranými hodnotami slnečného žiarenia.

Projekt je rozdelený do troch hlavných častí:

1. Exploračná dátová analýza (EDA) a predspracovanie dát
2. Trénovanie konvolučných neurónových sietí (CNN)
3. Transfer Learning a zhlukovanie

1.1 Použité technológie

- **Python** (jazyk): 3.13
- **polars**: 1.35.2
- **numpy**: 2.3.5
- **scikit-learn**: 1.7.2
- **matplotlib**: 3.10.7
- **seaborn**: 0.13.2
- **scipy**: 1.15.2
- **jupyter**: 1.1.1
- **ipykernel**: 7.1.0
- **pyarrow**: 22.0.0
- **pillow**: 12.0.0
- **tqdm**: 4.67.1
- **torch**: 2.7.0+xpu
- **torchvision**: 0.22.0+xpu
- **Intel Extension for PyTorch**: GPU akcelerácia na Intel Arc

1.2 Dataset

Dataset obsahuje dáta zo 4 mesiacov roku 2018:

- **Január (01)**: Zimné obdobie
- **Apríl (04)**: Jarné obdobie
- **Júl (07)**: Letné obdobie
- **Október (10)**: Jesenné obdobie

Celkový počet záznamov: 6 007 vzoriek s existujúcimi obrázkami

2 Časť 1: Exploračná dátová analýza

2.1 Načítanie a analýza dát


Po načítaní dát zo všetkých 4 mesiacov sme vykonali základnú štatistickú analýzu.

2.1.1 Štatistiky cieľovej premennej Irradiance

Štatistika	Hodnota
Minimum	0.06 W/m ²
Maximum	1136.56 W/m ²
Priemer	299.05 W/m ²
Medián	198.29 W/m ²
Smerodajná odchýlka	282.50 W/m ²

Tabuľka 1: Štatistiky slnečného žiarenia (Irradiance)

2.1.2 Vizualizácia distribúcie Irradiance




Obr. 1: Distribúcia cieľovej premennej Irradiance

Pozorovania:

- Distribúcia je pravostranná (right-skewed)
- Veľa vzoriek s nízkym žiarením (zamračené dni, nočné hodiny)
- Menší počet vzoriek s vysokým žiarením (jasné slnečné dni)

2.2 Distribúcia žiarenia podľa mesiacov




Obr. 2: Distribúcia slnečného žiarenia podľa mesiacov

Interpretácia:

- **Júl (07):** Najvyššie priemerné žiarenie – letné obdobie
- **Január (01):** Najnižšie priemerné žiarenie – zimné obdobie
- Apríl a Október majú podobné stredné hodnoty

2.3 Ukázky obrázků

2.3.1 Náhodné vzorky obrázků




Obr. 3: Náhodné vzorky obrázků oblohy s hodnotami Irradiance

2.3.2 Obrázky s nízkym a vysokým žiarením



(a) Obrázky s najnižším žiarením



(b) Obrázky s najvyšším žiarením


Obr. 4: Porovnanie obrázkov s extrémnym žiarením

Pozorovania:

- Nízke žiarenie: tmavá obloha, husté mraky, nočné/večerné hodiny
- Vysoké žiarenie: jasná modrá obloha, priame slnečné svetlo

2.4 Korelačná analýza

Analýzovali sme 15 numerických premenných a ich korelácie s cieľovou premennou Irradiance.




Obr. 5: Korelačná matica numerických premenných

2.4.1 Top 10 korelácií s Irradiance

Premenná	Korelácia
Pressure	+0.6085
PressureAvg	+0.6079
FanSpeed	-0.6060
BodyTemperature	+0.5878
PressureTemp	+0.5852
PressureTempAvg	+0.5846
HumidityTemp	+0.5837
FanCurrent	-0.5109
RelativeHumidity	+0.4684
HeaterCurrent	+0.4105

Tabuľka 2: Korelácie numerických premenných s Irradiance

2.5 Detailná analýza top features



Obr. 6: Scatter ploty top 6 korelovaných premenných vs Irradiance

Interpretácia:


- Pressure a BodyTemperature majú pozitívny lineárny vzťah so žiarením
- FanSpeed má negatívnu koreláciu – ventilátor sa zapína pri vyššom žiarení

2.6 Rozdelenie dát

Dataset bol rozdelený na trénovaciu, validačnú a testovaciu množinu:

Množina	Počet vzoriek	Podiel (%)
Trénovacia	4 204	70.0
Validačná	901	15.0
Testovacia	902	15.0
Celkom	6 007	100.0

Tabuľka 3: Rozdelenie datasetu



Obr. 7: Distribúcia Irradiance v jednotlivých splitoch

Kontrola: Distribúcie sú konzistentné naprieč všetkými splitmi.

3 Časť 2: Konvolučné neurónové siete (CNN)

3.1 Architektúra CNN

Navrhli sme vlastnú konvolučnú neurónovú sieť pre regresiu slnečného žiarenia:

Vrstva	Parametre	Popis
Input	$3 \times 128 \times 128$	RGB obrázkov
Conv Block 1	Conv2D + BN + ReLU + MaxPool	Extrakcia nízkoúrovňových features
Conv Block 2	Conv2D + BN + ReLU + MaxPool	Strednoúrovňové features
Conv Block 3	Conv2D + BN + ReLU + MaxPool	Vysokoúrovňové features
Flatten	–	Prevod na 1D vektor
FC + Dropout	Hidden neurons + ReLU	Plne prepojené vrstvy
Output	1 neuron	Predikcia Irradiance

Tabuľka 4: Architektúra CNN modelu

Pravidlá návrhu:

- Počet konvolučných kanálov $>$ počet FC neurónov
- Dropout aplikovaný len na FC vrstvy
- Batch Normalization po každej konvolúcii

3.2 Konfigurácie hyperparametrov

Testovali sme 5 rôznych konfigurácií:

Konfigurácia	Conv	FC	Dropout	WD	Epochs
1: Základná	[16,32,64]	[32,16]	0.65	0.03	8
2: Hlbšia sieť	[16,32,64,128]	[64,32]	0.65	0.03	8
3: Vyšší dropout	[16,32,64]	[32,16]	0.70	0.03	8
4: Väčší weight decay	[16,32,64]	[32,16]	0.65	0.10	8
5: Širšia sieť	[24,48,96]	[48,24]	0.65	0.04	8

Tabuľka 5: Konfigurácie CNN modelov

3.3 Výsledky tréovania CNN

Konfigurácia	Params	Train R ²	Test R ²	Test RMSE	Test MAE
1: Základná	173 457	0.9292	0.9275	76.49	53.09
2: Hlbšia sieť	698 065	0.9729	0.9722	47.39	30.14
3: Vyšší dropout	173 457	0.9346	0.9341	72.90	50.94
4: Väčší weight decay	173 457	0.9243	0.9231	78.75	53.70
5: Širšia sieť	389 401	0.9737	0.9744	45.43	31.37

Tabuľka 6: Výsledky všetkých CNN konfigurácií

3.3.1 Najlepšia konfigurácia

- Konfigurácia 5: Širšia sieť
- Test R²: **0.9744**
- Test RMSE: **45.43 W/m²**
- Test MAE: **31.37 W/m²**
- Počet parametrov: 389 401


3.3.2 Analýza overfittingu

Konfigurácia	Train R ²	Test R ²	Rozdiel
1: Základná	0.9292	0.9275	0.0017
2: Hlbšia sieť	0.9729	0.9722	0.0007
3: Vyšší dropout	0.9346	0.9341	0.0005
4: Väčší weight decay	0.9243	0.9231	0.0012
5: Širšia sieť	0.9737	0.9744	-0.0007

Tabuľka 7: Analýza overfittingu CNN modelov


Záver: Žiadna konfigurácia nevykazuje významný overfitting. Konfigurácia 5 má dokonca mierne lepší výkon na teste než na tréningu.

3.4 História tréovania najlepšieho modelu




Obr. 8: História tréovania Konfigurácie 5 (Širšia sieť)

3.5 Analýza reziduálov




Obr. 9: Reziduálna analýza najlepšieho CNN modelu

3.6 Porovnanie predikcií




Obr. 10: Porovnanie predikcií vs. skutočných hodnôt (100 vzoriek)

3.7 Vizualizácia konvolučných filtrov



Obr. 11: Filtre prvej konvolučnej vrstvy



Obr. 12: Filtre druhej konvolučnej vrstvy

3.8 Bonus: Testovanie na vlastných obrázkoch

Model bol testovaný na 5 vlastných fotografiách oblohy z Bratislavy:

Vlastné obrázky oblohy - Predikované slnečné žiarenie



Obr. 13: Predikcie na vlastných obrázkoch oblohy

Obrázok	Predikcia (W/m^2)
blumental_20251127_104827.jpg	824.38
FEI_20251128_092755.jpg	692.11
kuchajda_20251127_075407.jpg	490.92
kuchajda_20251127_154347.jpg	732.22
mlynska_dolina20251127_184021.jpg	1.76

Tabuľka 8: Predikcie na vlastných obrázkoch

Interpretácia:


- Model správne rozpoznal vysoké žiarenie pri jasnej oblohe
- Večerný/nočný obrázok správne klasifikovaný s nízkym žiarením (1.76 W/m^2)

3.9 Bonus: Predikcia žiarenia o 15 minút

Vytvorili sme model na predikciu budúceho žiarenia z aktuálneho obrázka:

Úloha	R^2	RMSE
Odhad aktuálneho žiarenia	0.9744	45.43
Predikcia o 15 minút	0.5901	180.40

Tabuľka 9: Porovnanie odhadu vs. predikcie



Obr. 14: Výsledky predikcie žiarenia o 15 minút

Záver: Predikcia budúceho žiarenia je výrazne ťažšia úloha kvôli dynamickým zmenám oblačnosti.

4 Časť 3: Transfer Learning a zhlukovanie

4.1 Extrakcia príznakov pomocou MobileNetV2

Pre transfer learning sme použili predtrénovaný model **MobileNetV2**:

- Predtrénovaný na ImageNet datasete
- Extrahované príznaky z poslednej konvolučnej vrstvy
- Veľkosť výstupného feature vektora: **62 720** dimenzií

4.1.1 Redukcia dimenzie pomocou PCA

Parameter	Hodnota
Pôvodná dimenzia	62 720
Redukovaná dimenzia (zhlukovanie)	50
Redukovaná dimenzia (regresia)	300
Vysvetlený rozptyl (50 komponentov)	74.81%
Vysvetlený rozptyl (300 komponentov)	90.07%

Tabuľka 10: Parametre PCA redukcie


4.2 Zhlukovanie pomocou K-Means

4.2.1 Výber optimálneho počtu zhlukov

Použili sme Elbow Method a Silhouette Analysis:


- Testované $k = 2$ až 10
- **Vybraný počet zhlukov: 7**

4.2.2 Vizualizácia zhlukov (t-SNE)




Obr. 15: 2D vizualizácia zhlukov pomocou t-SNE

4.2.3 Priemerné obrázky pre každý zhluk



Obr. 16: Priemerné obrázky pre jednotlivé zhluky

4.2.4 Distribúcia Irradiance podľa zhlukov



Obr. 17: Distribúcia slnečného žiarenia v jednotlivých zhlukoch

Interpretácia zhlukov:

- Zhluky s nízkym priemerným žiarením ($< 100 \text{ W/m}^2$): nočné/zamračené obdobia
- Zhluky so stredným žiarením ($100\text{--}600 \text{ W/m}^2$): polojasno, čiastočne oblačno
- Zhluky s vysokým žiarením ($> 600 \text{ W/m}^2$): jasná obloha, priame slnko

4.3 Transfer Learning - Stacking Ensemble

Pre regresiu sme použili Stacking Ensemble kombinujúci:

- **Gradient Boosting Regressor** (500 estimátorov, max_depth=8)
- **Random Forest Regressor** (300 estimátorov, max_depth=15)
- **Ridge Regression** ako finálny estimátor

4.3.1 Vstupy modelu

- 300 PCA komponentov z MobileNetV2 príznakov
- 2 tabuľkové príznaky (Pressure, Humidity)
- **Celkovo: 302 príznakov**

4.3.2 Výsledky Transfer Learning

Množina	R ²	RMSE	MAE	MSE
Trénovacia	0.9976	–	–	–
Validačná	0.9586	–	–	–
Testovacia	0.9601	56.73	29.15	3218.05

Tabuľka 11: Výsledky Transfer Learning modelu

4.4 Porovnanie CNN vs. Transfer Learning


Model	Test R^2	Test RMSE	Test MAE
CNN (Konfigurácia 5)	0.9744	45.43	31.37
Transfer Learning (Stacking)	0.9601	56.73	29.15
Rozdiel	-0.0143	+11.30	-2.22

Tabuľka 12: Porovnanie CNN a Transfer Learning


Analýza:

- CNN dosahuje vyššie R^2 a nižšie RMSE
- Transfer Learning má nižšie MAE – menšie priemerné chyby
- Oba prístupy dosahujú vysokú presnosť ($R^2 > 0.96$)

4.5 Vizualizácia výsledkov Transfer Learning




Obr. 18: Reziduálna analýza Transfer Learning modelu



Obr. 19: Porovnanie predikcií Transfer Learning modelu

4.6 Analýza najhorších predikcií



Obr. 20: Top 10 najhorších predikcií modelu

Model má tendenciu robiť najväčšie chyby pri:


- Extrémnych hodnotách žiarenia
- Prechodových podmienkach (čiastočne oblačno)
- Neobvyklých poveternostných situáciách

4.7 Bonus: Fúzia modelov


Porovnali sme výkon modelov s rôznymi typmi príznačov:

Model	R^2	RMSE	MAE
Obrazové príznaky (PCA 50)	0.9561	59.52	32.88
Tabuľkové príznaky	0.7722	135.59	92.08
Fúzia (obrazové + tabuľkové)	0.9574	58.64	32.29


Tabuľka 13: Porovnanie modelov s rôznymi príznačkami



Obr. 21: Porovnanie modelov: obrazové vs. tabuľkové vs. fúzia



Obr. 22: Porovnanie metrík R^2 a RMSE



Obr. 23: Dôležitosť príznakov vo fúznom modeli

Záver: Fúzia obrazových a tabuľkových príznakov prináša mierne zlepšenie oproti samotným obrazovým príznakom.

5 Záver

5.1 Zhrnutie výsledkov

Splnené tri časti zadania:

1. Exploračná dátová analýza

- Analýza 6 007 vzoriek zo 4 mesiacov
- Vizualizácia distribúcií a korelácií
- Rozdelenie dát 70/15/15

2. Konvolučné neurónové siete

- 5 konfigurácií s rôznymi hyperparametrami
- Najlepší model: $R^2 = 0.9744$, $RMSE = 45.43 \text{ W/m}^2$
- Žiadny významný overfitting

3. Transfer Learning a zhľukovanie

- Extrakcia príznakov pomocou MobileNetV2
- 7 zhľukov identifikovaných K-Means
- Stacking Ensemble: $R^2 = 0.9601$

5.2 Finálne porovnanie modelov

Model	Test R^2	Test RMSE	Poznámka
CNN (Konfig. 5)	0.9744	45.43	Najlepší výkon
Transfer Learning	0.9601	56.73	MobileNetV2 + Stacking
Fúzia (bonus)	0.9574	58.64	Obrazové + tabuľkové

Tabuľka 14: Finálne porovnanie všetkých modelov

Najlepší celkový model: CNN Konfigurácia 5 (Širšia sieť)

Použitie nástrojov umelej inteligencie

Pri vypracovaní zadania som využil nasledujúce AI nástroje ako podporné prostriedky:

- **Claude Opus 4.5 (2025):** Konzultácie pri návrhu architektúry CNN, brainstorming prístupov k transfer learning a diskusia o vhodných metódach zhlukovania.

Zdroje

1. PyTorch Documentation. (2025). *Convolutional Neural Networks*.
https://pytorch.org/tutorials/beginner/blitz/cifar10_tutorial.html
2. Intel Corporation. (2025). *Intel Extension for PyTorch - Installation Guide*.
<https://pytorch-extension.intel.com/installation>
3. scikit-learn Documentation. (2025). *Stacking Regressor*.
<https://scikit-learn.org/stable/modules/ensemble.html#stacked-generalization>
4. TorchVision Documentation. (2025). *MobileNetV2*.
<https://pytorch.org/vision/stable/models/mobilenetv2.html>
5. van der Maaten, L., & Hinton, G. (2008). *Visualizing Data using t-SNE*.
<https://www.jmlr.org/papers/v9/vandermaaten08a.html>