

I-SUNS: Zadanie č.3

KONVOLUČNÉ SIETE A PRENOS VEDOMOSTÍ

Vo vybranom programovacom jazyku implementujte program, ktorý bude odhadovať slnečné žiarenie z fotografie oblohy. Dáta sú dostupné na adrese [Google Drive](#).

Čas odovzdania je určený časom vloženia do AIS. Deadline pre získanie 15 bodov je 5.12.2024 o 8:00 a 10:00 pred vašim cvičením. Keďže ide o odovzdanie na posledné cvičení, neskoršie odovzdanie už nie je možné. Ak k tomuto dátumu nebudete mať odovzdané všetky tri zadania, budete z cvičení hodnotení známkou **nezapočítané**.

- **Pracujte so všetkými 3 farebnými kanálmi - za konverziu na šedotónové obrázky bude zo získaného počtu bodov udelená len polovica!**
- Spoznajte dáta:
 - Analyzujte dostupné tabuľkové dáta a vizualizujte vzťahy medzi jednotlivými premennými vzhľadom na cieľovú premennú. Keďže máme k dispozícii obrazové aj tabuľkové dáta, rozdeľte ich na tri časti – trénovaciu, validačnú a testovaciu množinu (X-obrázky, Y-Stĺpec Irradiance). Pri rozdeľovaní zabezpečte, aby boli dáta správne spárované a vzájomne konzistentné. **2b**
- Vytvorte a natrénujte konvolučnú neurónovú sieť na odhad slnečného žiarenia (**bez vypracovania tejto časti bude zadanie hodnotené 0 bodmi!**), výsledný (najlepší) model nesmie trpieť podtrénovaním ani pretrénovaním:
 - Pre trénovaciu, validačnú a testovaciu množinu, si pripravte generátor dát, nezapodnajte dáta normalizovať a vhodne im zmeniť veľkosť - pozor na zamiešanie (shuffle) dát pri použití generátorov. POZOR: vstup je obrázok a výstup z hodnoty z tabuľkových dát. **0.5b**
 - Navrhajte sieť s aspoň 2 konvolučnými vrstvami **a** využite niektoré z regularizačných alebo normalizačných techník aby ste zabránili pretrénovaniu(aspoň 2). Skúste niekoľko (aspoň 5) cielených konfigurácií hyperparametrov, všetky úspešnosti(MSE, MAE, RMSE a R2) pre **trénovaciu** aj **testovaciu** množinu zobrazte **v 1 tabuľke**. Nezapodnajte aj na vykreslenie reziduálov (**trénovacej** aj **testovacej**). **2b**
 - Nezapodnajte na dobré praktiky zo zadania 1 a 2 - sledujte a zobrazte priebehy trénovania, poriadne evaluujte na **trénovacej** a **testovacej** množine (analyzujte reziduály, môžete vykresliť aj predikované vs skutočné hodnoty alebo iné).

V tabuľke uveďte úspešnosti(**MSE, MAE, RMSE a R2**) pre **trénováciu** aj **testováciu** množinu, grafy a reziduály stačí zobrazit' pre najlepšie tréovanie. **1b**

- Vzhľadom na náročnosť výpočtov si nezabudnite vytvárať checkpointy počas tréovania (nie je povinné).
- Zhlukujte vaše výsledky pomocou princípov *transfer learning*:
 - Jednu vyššie použitú sieť predtrénovanú na datasete ImageNet(MobileNet, Resnet, EfficientNET...) využite na extrakciu príznakov z obrazových dát (miesto konkrétneho čísla výslednej regresie bude vracať vektor popisujúci obraz). Pozrite sa na množstvo parametrov(čím menej parametrov tým budú výpočty rýchlejšie) Zakódujte celý dataset, do dataframe-u si uložte vyextrahované príznaky (každý do samostatného stĺpca), cestu k obrázku (pre ďalšiu analýzu) a pridajte stĺpec s výstupnou hodnotou (Irradiance z tabuľkových dát). **2b**
 - **Príznaky** (iba príznaky!) zhlukujte a analyzujte výsledky - môžete si pomôcť aj zmenšením dimenzie. Body budú udelené nasledovne (ak budete mať viac než 10 zhlukov, dajte do dokumentácie len tie najzaujímavejšie):
 - * Využitie zhlučovacieho algoritmu na vytvorenie zhlukov. **1b**
 - * Zobrazenie (pod)množiny obrázkov pre všetky zhluky - obrázky si kludne zmenšíte, aby sa Vám zmestili na menšiu plochu. **1b**
 - * Zobrazenie priemerného obrázku pre všetky zhluky. **0.5b**
 - * Analýza výsledkov zhlučovania ¹. **1b**
- Natrénujte sieť na vygenerovaných príznakoch. Môžete si **vybrať** jeden z dvoch spôsobov (**bez vypracovania tejto časti bude zadanie hodnotené 0 bodmi!**)
 - v tejto časti je potrebné dosiahnuť lepšie výsledky ako pri vytvorení vlastnej konvolučnej siete:
 - **Možnosť 1** Na pripravených príznakoch trénujte ľubovoľný regresor z predošlých zadání (t.j. neurónovú sieť, SVM, rozhodovací strom, model využívajúci súborové učenie) - môžete si pomôcť aj zmenšením dimenzie. Dajte si pozor na výber modelu - je potrebné dosiahnuť lepšie výsledky ako pri vlastnej konvolučnej sieti z prvej časti zadania.
 - **Možnosť 2** Dotrénujte posledné vrstvy ImageNet siete (ostatné budú zamrazené!).

¹analýza výsledkov znamená, že budete vedieť povedať, aké obrázky sú vo vnútri clustrov - napr. oblačno; fotky, kde je vidno veľa oblohy a pod. - malo by sa to odzrkadliť aj na priemerných obrázkoch

Body budú udelené nasledovne:

- Natrénovanie modelu **2b**
- Zobrazenie priebehov tréovania (povinne, ak je to možné - t.j. neurónové siete v oboch prípadoch), reziduály, úspešnosti na **trénovacej** a **testovacej** množine + **analýza**: Kde sa model mýli? Prečo? **2b**

Nepovinné úlohy

- Zobrazte filtre z konvolučných vrstiev - farebne. **0.5b**
- Vytvorte si vlastnú malú (aspoň 5 obrázkov) databázu obrázkov oblohy (nie obrázky stiahnuté z internetu!) a otestujte vašu sieť na nich. **1b**
- Transformujte problém z odhadu na predikciu(t.j. aká hodnota žiarenia bude o 15 minút) a natrénujte ľubovoľný model. **3b**
- Vytvorte fúziu modelov, ktoré budú kombinovať tabuľkové a obrazové dáta. **3b**
- Použite na regresiu model založený na architektúre Transformerov. **3b**